

Vodič za Fazu 1 (KT1 — prva kontrolna tačka): Movie NLP Success Analyzer

Kurs: Sistemi za Istraživanje i Analizu Podataka (SIAP)

Tim: Laslo Uri (E2 163/2023), Denis Dautović (E2 166/2023), Nikola Janković (E2 130/2025)

Datum: Mart 2026

Kontrolna tačka: KT1 (Prva kontrolna tačka)

Ovaj dokument opisuje **šta KT1 zahteva** i **kako isporučiti** Movie NLP Success Analyzer: kontrolna lista, lokacije u kodu, objašnjenja i linkovi.


Sadržaj

- [1. Zahtevi KT1](#)
- [2. KT1 isporuke — kontrolna lista](#)
- [3. Preporučeni redosled radova](#)
 - [3.1 Faza A — Podaci i EDA](#)
 - [3.2 Faza B — Baseline modeli](#)
- [4. Pipeline podataka i NLP \(obuhvat KT1\)](#)
- [5. Lokacije u kodu](#)
- [6. Ciljevi evaluacije \(KT1 baseline\)](#)
- [7. Prezentacija i izveštaj](#)

1. Zahtevi KT1

(SIAP — Sistemi za istraživanje i analizu podataka.)

Zahtev	Zašto je važno za ovaj projekat
Kompletan dataset	TMDB metapodaci + OpenSubtitles tekst + oznake Akademije; spojeno i očišćeno za modelovanje.
EDA (Exploratory Data Analysis — eksplorativna analiza podataka)	Razumeti distribucije, korelacije, balans klasa i pokrivenost titlova pre modelovanja. EDA
Baseline modeli	Najmanje LR (logistička regresija) , RF (slučajna šuma) , XGBoost — fiksni hiperparametri; tuning nije obavezan na KT1. sklearn
NLP feature-i	Izvlačenje feature-a iz teksta titlova: TF-IDF (npr. SVD), sentiment (npr. VADER), leksička raznolikost; kombinacija sa metapodacima.
Tretman neuravnoteženosti klasa	SMOTE i/ili class_weight za predikciju nagrada (manjinska klasa ~13%). SMOTE
Evaluacija	Stratifikovani split 70/15/15 ; F1 , AUC (i po želji balansirana tačnost); optimizacija nije obavezna.
Prezentacija	~10 min: uvod → podaci → EDA → NLP feature-i → baseline modeli → zaključci.



2. KT1 isporuke – kontrolna lista

Stavka	Gde	Zašto
Dataset	data/processed/ : final_movie_list.csv , TMDB + titlovi + nagrade spojeni	Jedinstvena tabela za modelovanje sa ciljevima i ID-ovima za NLP spajanje.
EDA	01_eda.ipynb	Distribucije ciljeva, budžet/prihod, žanr, vremenski trendovi, pokrivenost titlova, korelacije.
NLP feature-i	02_nlp_features.ipynb + src/nlp_features.py	Tekstualne statistike, sentiment, leksička raznolikost, TF-IDF matrica; sačuvano za 03.
Baseline modeli	03_baseline_models.ipynb + src/models.py	LR, RF, XGB na progresivnim feature setovima; SMOTE/class_weight za award.
Feature setovi	1_text_basic → 3_text_full (NLP + SVD) → 4_+genre ... 8_+vote_revenue	Prihod isključen iz komercijalnih setova (data leakage).
Metrike	F1, F1@opt, AUC, balansirana tačnost; tabele i heatmap	Reproduktivna evaluacija; F1@opt za neuravnotežen award zadatak.
Split	70% train / 15% val / 15% test, stratifikovano	Traži se u okviru kursa; val za izbor praga.
Izveštaj	phase_01/README.md	Problem, podaci, EDA, NLP, baseline rezultati, zaključci.

3. Preporučeni redosled radova (KT1)

3.1 Faza A — Podaci i EDA

1. Sastavljanje dataseta

Osigurati da `data/processed/` sadrži spojene TMDb + nagrade; dodati pokrivenost titlovima i labela

`is_commercial / is_award_winner`. Ispraviti **data leakage**: `is_commercial = (revenue/budget ≥ 2)` → **ne** koristiti `revenue` u komercijalnim feature setovima.

Zašto: Čisti ciljevi i feature-i bez curenja su obavezni pre bilo kog modela.

2. EDA notebook (`01_eda.ipynb`)

Pregled, distribucije ciljeva, finansijski podaci, žanr, vremenski trendovi, pokrivenost titlova, analiza korelacija (npr. point-biserial sa ciljevima).

Zašto: Pokazuje razumevanje podataka i podržava metodologiju u izveštaju.

3. Izvlačenje NLP feature-a (`02_nlp_features.ipynb` , `src/nlp_features.py`)

Učitati tekstove titlova, očistiti, računati: statistike reči/rečenica, leksička raznolikost, sentiment (npr. VADER), TF-IDF; sačuvati `nlp_features.csv` i TF-IDF matricu (+ ID-ovi) za modelovanje.

Zašto: Baseline modeli u 03 zahtevaju ove feature-e; TF-IDF + SVD u setu `3_text_full`.

3.2 Faza B — Baseline modeli

4. Učitavanje podataka i feature setovi (`03_baseline_models.ipynb`)

Učitati glavni dataset + NLP feature-e, spojiti, kreirati žanr dummy-e, filtrirati na validan budžet/prihod/runtime + titlovi. Definisanje **osam progresivnih feature setova** (`1_text_basic` ... `8_+vote_revenue`); komercijalni setovi bez `revenue`.

Zašto: Izdvaja doprinos svakog faktora (tekst vs metapodaci).

5. Treniranje i evaluacija


Koristiti `create_splits`, `get_baseline_models`, `train_baseline` iz `src/models.py`. Za svaki set i oba cilja: stratifikovani split, opciono SMOTE za award, trenirati LR/RF/XGB; prikupiti F1, F1@opt, AUC, balansiranu tačnost.

Zašto: Jedan pipeline; rezultati u jednoj tabeli i heatmapama.

6. Zaključci


Kratak rezime: koji feature set daje najbolji F1/AUC; commercial vs award; napomena da parametri nisu optimizovani (KT2).

Zašto: Direktno odgovara na „šta je KT1 postigao?“ za prezentaciju i izveštaj.




4. Pipeline podataka i NLP (obuhvat KT1)

Korak	Izvor	Rezultat	Korišćenje
TMDB metapodaci	API / data/raw/	Budžet, prihod, runtime, žanrovi, vote_count, release_date	EDA, modelovanje
Nagrade	CSV	is_award_winner	Cilj
Komercijalna oznaka	Izvedeno	is_commercial = (revenue/budget ≥ 2)	Cilj; isključiti revenue iz komercijalnih feature-a
Titlovi	OpenSubtitles / .txt	Sirovi tekst po filmu	02_nlp_features
NLP feature-i	nlp_features.py	word_count, sentiment, leksički, TF-IDF matrica	03_baseline_models
SVD	03_baseline_models.ipynb	N_SVD komponenti (npr. 100) iz TF-IDF	Set 3_text_full



5. Lokacije u kodu

Cilj	Fajl	Akcija
Učitavanje i spajanje	src/data_loader.py	load_main_dataset , load_nlp_features , merge_datasets
Žanr dummy-i	src/data_loader.py	get_unique_genres , create_genre_dummies
EDA	01_eda.ipynb	Kompletna EDA; figure u figures/
NLP ekstrakcija	src/nlp_features.py	Čišćenje teksta, sentiment, leksički, TF-IDF; batch obrada
NLP notebook	02_nlp_features.ipynb	Izgradnja nlp_features.csv, tfidf_matrix.npz, ID korpusa
Splitovi i modeli	src/models.py	prepare_modeling_data , create_splits , get_baseline_models , train_baseline
Rezultati i grafovi	src/models.py	results_table , f1_at_optimal_threshold , plot_confusion_matrices , plot_roc_curves
Baseline pipeline	03_baseline_models.ipynb	Definisanje FEATURE_SET_CONFIG, pokretanje train/eval, heatmape, SMOTE vs class_weight



6. Ciljevi evaluacije (KT1 baseline)

Zadatok	Očekivanje na KT1	Napomena
Commercial	F1 ~0.60–0.68, AUC ~0.70–0.78 (set 7_+runtime)	Revenue isključen; budžet, runtime, vote_count, žanr, NLP.
Award	F1(opt) ~0.50–0.55, AUC ~0.78–0.87	Neuravnoteženost; F1 na optimalnom pragu; SMOTE ili class_weight.

Rezultati **ne moraju biti jaki** na KT1; cilj je **reproduktivni baseline** i jasna metodologija. Optimizacija hiperparametara i SVM su za KT2.

7. Prezentacija i izveštaj

- **Prezentacija:** ~10 min. Redosled: uvod → podaci → EDA → NLP feature-i → baseline modeli → zaključci. Vidi [Phase_01_KT1_Defense_SR.md](#).
- **Izveštaj:** README.md u phase_01 — problem, podaci, EDA, NLP, baseline rezultati, zaključci.
- **Kod:** Ovaj repozitorijum; deliverable za KT1 je phase_01/ (notebooki 01–03 + src/).

Ovaj dokument je **vodič za implementaciju Faze 1** i podrška konzistentnoj isporuci za KT1.