

Specifikacija Faze 1 (KT1 — prva kontrolna tačka): Movie NLP Success Analyzer

Kurs: Sistemi za Istraživanje i Analizu Podataka (SIAP)

Tim: Laslo Uri (E2 163/2023), Denis Dautović (E2 166/2023), Nikola Janković (E2 130/2025)

Datum: Mart 2026

Kontrolna tačka: KT1 (Prva kontrolna tačka)

Sadržaj

- [Apstrakt](#)
- [1. Uvod i cilj projekta](#)
- [2. Prikupljanje i priprema podataka](#)
 - [2.1 Pregled pipeline-a](#)
 - [2.2 Korak po korak — šta radi svaka skripta](#)
 - [2.3 Šta na kraju imamo u podacima](#)
- [3. Šta imamo u Fazi 1 \(Phase 01\) — pregled](#)
- [4. Notebook 01 — Eksplorativna analiza podataka \(EDA\)](#)
 - [4.1 Struktura notebooka i šta radi svaka sekcija](#)
- [5. Notebook 02 — Izvlačenje NLP obeležja](#)
 - [5.1 Šta radi svaka sekcija](#)
- [6. Notebook 03 — Baseline modeli](#)
 - [6.1 Šta radi svaka sekcija](#)
 - [6.2 Šta pokazuju slike baseline modela](#)
- [7. Šta koristimo, zašto, šta očekujemo i šta smo dobili](#)
 - [7.1 Tehnike i alati](#)
 - [7.2 Očekivanja \(KT1\) i ostvareni rezultati](#)
 - [7.3 Da li smo zadovoljni?](#)
- [8. Zaključak](#)

Apstrakt


Ovaj dokument predstavlja **specifikaciju za prvu fazu (prvu kontrolnu tačku — KT1)** projekta *Movie NLP Success Analyzer*. Opisuje kompletan pipeline u okviru KT1: od prikupljanja podataka iz više izvora (TMDB, titlovi, nagrade) do eksplorativne analize, izvlačenja NLP obeležja iz teksta titlova i treniranja baseline modela za dve binarne predikcije — komercijalni uspeh ($ROI \geq 2$) i nominacija za Oskara. Cilj specifikacije je da na jasan i razumljiv način definiše šta imamo, kako smo to dobili, šta radi svaki korak (uključujući ćelije u notebookima i značenje svake slike), koje tehnike koristimo i zašto, te da li smo zadovoljni rezultatima. Dokument je namenjen i čitaocima bez dubokog predznanja algoritama i NLP tehnika.

1. Uvod i cilj projekta

Cilj projekta je da se **predvidi uspeh filma** na osnovu:

1. **Komercijalni uspeh** — da li će film ostvariti prihod bar duplo veći od budžeta ($ROI \geq 2$).
2. **Kritički uspeh** — da li će film dobiti nominaciju za Oskar.


Za to koristimo i **metapodatke** (budžet, trajanje, žanr, broj glasova) i **tekst titlova** (dijalog), iz koga izvlačimo obeležja obrade prirodnog jezika (NLP): sentiment, leksička raznolikost, TF-IDF reprezentacija teksta. Faza 1 postavlja **reproduktivni baseline**: čist dataset, EDA, NLP feature-i i tri baseline klasifikatora (logistička regresija, slučajna šuma, XGBoost) bez optimizacije hiperparametara.



2. Prikupljanje i priprema podataka

Podatke smo prikupili u **jednom sekvencijalnom pipeline-u** od deset skripti u modulu `data_pipeline/` . Svaka skripta ima jednu ulogu; izlaz jedne služi kao ulaz sledeće. Na kraju dobijamo jednu glavnu tabelu za modelovanje i folder sa tekstovima titlova za NLP.

2.1 Pregled pipeline-a



Zašto ovaj redosled? Prvo gradimo listu filmova sa finansijama i nagradama; tek onda skidamo titlove samo za te filmove i proveravamo kvalitet fajlova. Na kraju proveravamo balans klasa i eventualnu pristrasnost skrejpera.

2.2 Korak po korak — šta radi svaka skripta

Skripta, ulaz i izlaz	Opis
1. fetch_tmdb.py Ulaz: TMDB API ključ (<code>.env</code>). Izlaz: <code>data/raw/tmdb_metadata/movies_YYYY.csv</code> (76 fajlova).	Preuzima metapodatke filmova iz TMDB API-ja: po godinama od 1950. do 2025., po 500 „top“ filmova godišnje. Čuva rezultat u CSV po godinama da se ne izgubi ništa ako skripta pukne.
2. enrich_tmdb_data.py Ulaz: Raw TMDB CSV-ovi. Izlaz: <code>data/processed/tmdb_enriched.csv</code> .	Za svaki film iz raw fajlova dohvaća budžet , prihod i IMDb ID (potrebno za kasnije preuzimanje titlova). Obradjuje u batch-evima i pauzira ako API ograniči broj zahteva.
3. fetch_awards.py Ulaz: Wikipedia API. Izlaz: <code>awards_master_partial.csv</code> , <code>awards_minor_categories.csv</code> .	Prikuplja podatke o filmskim nagradama (Oskar, BAFTA, Zlatni globus itd.) preko Wikipedia API-ja. Parsira HTML tabele, čisti naslove filmova i formira jedinstvenu listu nagrađenih/nominovanih filmova.
4. merge_and_filter.py Ulaz: TMDB + enriched + awards. Izlaz:	„Veliki filter“ : spaja TMDB metapodatke, obogaćene finansije i nagrade u jednu master tabelu. Ostavlja samo filmove koji ispunjavaju

Skripta, ulaz i izlaz	Opis
data/processed/final_movie_list.csv (12 722 filma).	bar jedan od uslova: imaju validne finansijske podatke (budžet/prihod > 1000), imaju veliku nagradu ili imaju dovoljno glasova (dokaz da je film relevantan). Takođe izračunava labele: <code>is_commercial</code> ($ROI \geq 2$), <code>is_award_winner</code> .
5. scrape_transcripts.py Ulaz: <code>final_movie_list.csv</code> . Izlaz: <code>data/raw/subtitles/{tmdb_id}.txt</code> (~7 400 fajlova).	Preuzima tekst titlova sa weba za filmove iz finalne liste. Koristi rotaciju User-Agent zaglavlja da izbegne blokadu; fuzzy podudaranje naslova osigurava da se skine titl za pravi film.
6. audit_files.py Ulaz: folder <code>subtitles/</code> . Izlaz: <code>data/processed/audit_report.csv</code> .	Proverava kvalitet skinutih fajlova: flaguje previše male fajlove (< 2 KB), fajlove koji sadrže HTML stranice greške (npr. 404) ili Cloudflare blokadu.
7. clean_bad_files.py Ulaz: Audit report. Izlaz: korumpirani fajlovi uklonjeni.	Briše korumpirane fajlove iz audit izveštaja. Pre brisanja traži ručnu potvrdu („DELETE“) u terminalu.
8. create_downloaded_manifest.py Ulaz: <code>subtitles/</code> , <code>final_movie_list.csv</code> . Izlaz: <code>data/processed/downloaded_movies.csv</code> .	Upoređuje šta fizički postoji na disku sa finalnom listom filmova i kreira konačni manifest : CSV u kome je garantovano da svaki red ima odgovarajući validan <code>.txt</code> fajl.
9. check_balance.py Ulaz: <code>downloaded_movies.csv</code> . Izlaz: izveštaj u konzoli.	Analizira balans klasa (npr. koliko ima dobitnika nagrada naspram ostalih). Korisno da se unapred vidi da li će trebati SMOTE ili drugo balansiranje.
10. compare_datasets.py Ulaz: finalna lista vs downloaded. Izlaz: grafikoni upoređivanja u <code>data/processed/</code> .	Vizuelno proverava da li je skrejpung uveo sistematsku pristrasnost (npr. da li su stariji filmovi ili određeni žanrovi manje zastupljeni u skinutim titlovima). Čuva grafikone u <code>data/processed/</code> .


2.3 Šta na kraju imamo u podacima

- **final_movie_list.csv** — 12 722 filma, 15 kolona: `id`, `budget`, `revenue`, `imdb_id`, `runtime`, `release_date`, `genres`, `original_title`, `title`, `vote_count`, `is_commercial`, `is_award_winner`, `is_popular`, `genres_list`, `roi`. Ovo je glavni izvor za EDA i za spajanje sa NLP obeležjima.
- **data/raw/subtitles/** — oko 7 423 tekstualna fajla (`{tmdb_id}.txt`), jedan po filmu. Tekst je sirovi sadržaj titlova (sa vremenskim oznakama, tagovima itd.), koji se u Fazi 1 čisti i koristi za izvlačenje NLP obeležja.

Zašto je važno: Bez ovog pipeline-a ne bismo imali ni jedinstvenu tabelu sa ciljevima (`is_commercial`, `is_award_winner`) ni tekst za NLP. Data leakage smo izbegli tako što **revenue** nije uključen u obeležja za predikciju komercijalnog uspeha (pošto je `is_commercial` definisan kao $ROI = revenue/budget \geq 2$).

3. Šta imamo u Fazi 1 (Phase 01) — pregled

Faza 1 sastoji se od tri Jupyter notebooka, zajedničkog koda u `src/` i foldera sa slikama.



Komponenta	Namena
01_eda.ipynb	Eksplorativna analiza: struktura dataseta, distribucije ciljeva, finansije, žanrovi, vreme, nedostajući podaci, pokrivenost titlovima, korelacije. Generiše 16 slika u <code>figures/</code> .
02_nlp_features.ipynb	Učitava titlove, čisti tekst, izvlači NLP obeležja (statistike teksta, leksička raznolikost, VADER sentiment, TF-IDF) i snima <code>nlp_features.csv</code> i TF-IDF matricu. Generiše 6 slika.
03_baseline_models.ipynb	Učitava glavni dataset i NLP obeležja, definiše 8 progresivnih setova obeležja, trenira LR / RF / XGB za oba cilja (komercijalni i nagrada), prikazuje tabele i heatmape. Generiše 10 slika.
src/data_loader.py	<code>load_main_dataset</code> , <code>load_nlp_features</code> , <code>merge_datasets</code> , <code>get_unique_genres</code> , <code>create_genre_dummies</code> — učitavanje i spajanje podataka za EDA i modelovanje.
src/nlp_features.py	Čišćenje teksta, izvlačenje osnovnih statistika, leksičke raznolikosti, sentimenta (VADER), TF-IDF; batch obrada.
src/models.py	<code>prepare_modeling_data</code> , <code>create_splits</code> , <code>get_baseline_models</code> , <code>train_baseline</code> , funkcije za tabele rezultata, konfuzione matrice, ROC krive, važnost obeležja.

4. Notebook 01 — Eksplorativna analiza podataka (EDA)

Notebook **01_eda.ipynb** koristi glavni dataset (`final_movie_list.csv`) učitavan preko `src.data_loader.load_main_dataset` . Loader parsira kolonu `genres` u listu i dodaje kolonu `roi` (revenue/budget). Cilj EDA je da razumemo distribucije, nedostajuće vrednosti, korelacije i spremnost podataka za modelovanje.

4.1 Struktura notebooka i šta radi svaka sekcija

- **Uvod i setup**

Uvoze se `pandas` , `numpy` , `matplotlib` , `seaborn` i `load_main_dataset` , `safe_literal_eval` . Postavljaju se putanje: `DATA_DIR` , `PROCESSED_DIR` , `RAW_DIR` , `SUBTITLES_DIR` , `FIGURES_DIR` .


- **1. Dataset overview**

- Učitava se dataset i ispisuje `shape` (12 722, 15) i liste kolona.
- Objašnjenje: ciljne promenljive su `is_commercial` , `is_award_winner` , `is_popular` .
- `df.dtypes` — tipovi kolona.
- `df.describe()` — osnovne statistike za brojčane kolone (uključujući ROI).
- Prikaz prvih redova — kako izgleda jedan zapis (budžet, prihod, žanrovi, labela).

- **2. Target distributions**

Vizuelizacija broja filmova po ciljnoj promenljivoj (komercijalni uspeh, nagrada, popularnost). Pokazuje neuravnoteženost: npr. nagrade su manjinska klasa (~13%).

Slika: `01_eda_01_target_distributions.png` — bar plot distribucija ciljeva.




Šta pokazuje slika: Broj filmova sa oznakom True/False za svaki od tri cilja. Komercijalni uspeh i popularnost su približno uravnoteženi; nagrade su manjinska klasa (~13% True), što zahteva SMOTE ili `class_weight` pri treniranju.

- **3. Financial distributions**

Histogrami za budget , revenue , roi (često log skala zbog ekstremnih vrednosti).

Slika: 01_eda_02_financial_distributions.png — raspodele budžeta, prihoda i ROI-ja.




Šta pokazuje slika: Histogrami su jako iskrivljeni udesno — većina filmova ima nizak budžet/prihod, a malo ih ima ekstremno visoke vrednosti. Zato u modelu koristimo log transformaciju (npr. budget_log).

- **4. Budget vs revenue**

Scatter plot budžet–prihod (obično log-log). Pokazuje da veći budžet ne garantuje veći prihod; ima i autlajera.

Slika: 01_eda_03_budget_vs_revenue.png .




Šta pokazuje slika: Rasip u log-log skali: veći budžet ne garantuje veći prihod. Ima izrazitih autlajera (filmovi sa malim budžetom a velikim prihodom). To potvrđuje da predikcija komercijalnog uspeha nije trivijalna.

- **5. Financial boxplots by success**

Boxplot-ovi finansijskih metrika podeljeni po `is_commercial` (i eventualno `is_award_winner`). Vidimo da uspešni filmovi imaju viši medijan prihoda.

Slika: 01_eda_04_financial_boxplots.png .




Šta pokazuje slika: Kada podelimo filmove na uspešne i neuspešne (po `is_commercial` ili `is_award_winner`), uspešni imaju viši medijan prihoda; razlika u budžetu je manje izražena. Finansijski podaci nose signal za cilj.

- **6. Genre frequency**

Broj filmova po žanru (iz `genres_list`). Npr. Drama, Comedy, Thriller su među najčešćim.

Slika: 01_eda_05_genre_frequency.png .




Šta pokazuje slika: Drama, Comedy i Thriller dominiraju po broju filmova; žanr je važan za model jer ćemo ga kodirati kao dummy obeležja (npr. `genre_drama`).

- **7. Genre success rates**

Stopa uspeha (npr. udeo `is_commercial == True`) po žanru. Npr. Adventure, Sci-Fi imaju više uspešnih; Documentary, TV Movie manje.

Slika: 01_eda_06_genre_success_rates.png .




Šta pokazuje slika: Stope uspeha ($ROI \geq 2$ ili nagrada) po žanru se razlikuju: Adventure, Sci-Fi, Action često imaju više uspešnih; Documentary, TV Movie manje. Žanr je korisno obeležje za oba cilja.

• 8. Genre co-occurrence

Koja se žanra često javljaju zajedno (npr. Drama + Romance).

Slika: 01_edu_07_genre_cooccurrence.png .




Šta pokazuje slika: Koja se žanra često javljaju zajedno (npr. Drama + Romance). Filmovi imaju više žanrova; heatmapa pomaže da se vidi struktura podataka i da se ne duplira signal u dummy obeležjima.

- **9. Temporal production**

Broj filmova po godini ili deceniji — rast produkcije tokom vremena.

Slika: 01_edu_08_temporal_production.png .




Šta pokazuje slika: Broj filmova po godini/deceniji naglo raste — od nekoliko stotina u 1950-im do hiljada u 2010-im. Dataset nije uniforman u vremenu; release_year može biti korisno obeležje.

- **10. Temporal financials**

Prosečan budžet/prihod po vremenskom periodu.

Slika: 01_edu_09_temporal_financials.png .




Šta pokazuje slika: Prosečan budžet i prihod po deceniji — rastu tokom vremena, sa vrhom u 2000-im/2010-im. Potvrđuje da vremenska komponenta može doprineti modelu.

- **11. Temporal success rates**

Stopa komercijalnog uspeha i stope nagrada po deceniji. Pokazuje pad stope nagrada u novijim decenijama (više filmova, ista količina nagrada).

Slika: 01_edu_10_temporal_success_rates.png .




Šta pokazuje slika: Stopa komercijalnog uspeha i udela nagrađenih filmova po deceniji. U novijim decenijama udeo nagrađenih opada (više filmova, isti broj nagrada) — važno za interpretaciju neuravnoteženosti.

• 12. Runtime and vote count distributions

Histogrami za runtime i vote_count.

Slika: 01_eda_11_runtime_votes_distributions.png.




Šta pokazuje slika: Runtime je grupisana oko 90–120 min; vote_count je jako iskrivljena udesno (malo filmova ima hiljade glasova). Zato koristimo vote_count_log u modelu.

• 13. Runtime and votes by success

Boxplot-ovi runtime/vote_count podeljeni po uspehu (komercijalni / nagrada).

Slika: 01_eda_12_runtime_votes_by_success.png.




Šta pokazuje slika: Uspešni filmovi (komercijalni ili nagrađeni) imaju u proseku više glasova i nešto duži runtime. Oba obeležja su opravdana u progresivnim setovima.

• 14. Missing data heatmap

Heatmapa nedostajućih vrednosti po kolonama (ili po uzorcima). Pokazuje gde su praznine (npr. budget = 0, revenue = 0).

Slika: 01_eda_13_missing_data_heatmap.png .




Šta pokazuje slika: Gde nedostaju podaci (npr. budget = 0, revenue = 0). Za modelovanje filtriramo na filmove sa validnim budget, revenue i runtime da ne bismo uvodili lažne vrednosti.

- **15. Subtitle coverage**

Koliko filmova ima titlove (presek sa `data/raw/subtitles/`). Obično bar plot ili pie: npr. ~58% ima titlove.

Slika: `01_edu_14_subtitle_coverage.png` .




Šta pokazuje slika: Oko 58% filmova ima titlove; ostali ne ulaze u modeling subset sa NLP obeležjima. Pokrivenost je dovoljna za smislenu analizu teksta.

- **16. Feature correlations**

Korelaciona matrica brojčanih obeležja (Pearson).

Slika: `01_edu_15_feature_correlations.png` .




Šta pokazuje slika: Pearson korelacije između brojčanih obeležja. Budget, revenue i vote_count su međusobno povezani; korisno za razumevanje multikolinearnosti i zašto izostavljamo revenue za commercial.

- **17. Point-biserial correlations**

Korelacija svakog brojčanog obeležja sa binarnim ciljem (`is_commercial` , `is_award_winner`). Pokazuje šta je najjače povezano sa uspehom: npr. `vote_count` , `revenue` (za `commercial`, ali `revenue` se ne sme koristiti zbog leakage-a), `runtime` za nagrade.

Slika: 01_edu_16_point_biserial_correlations.png .



Šta pokazuje slika: Snaga povezanosti svakog obeležja sa ciljem. Za komercijalni uspeh najjači su `vote_count` i `revenue` (`revenue` ne smemo koristiti); za nagrade `runtime` i `vote_count`. To usmerava izbor obeležja u setovima 7 i 8.

Zaključak EDA: Dataset ima smisla za modelovanje; postoje jasne korelacije sa ciljevima; neuravnoteženost za nagrade zahteva pažnju (SMOTE ili `class_weight`); pokrivenost titlovima (~58%) dovoljna je za NLP.

5. Notebook 02 — Izvlačenje NLP obeležja

Notebook **02_nlp_features.ipynb** učitava listu filmova i folder sa titlovima, čisti tekst i poziva funkcije iz `src/nlp_features.py` da izračunaju sva obeležja. Rezultat se čuva u `nlp_features.csv` i TF-IDF matrica (+ vocab i corpus IDs) za upotrebu u notebooku 03.

5.1 Šta radi svaka sekcija

- **Setup**

Uvoze se moduli iz `nlp_features` : čišćenje teksta, osnovne statistike, leksička raznolikost, sentiment (VADER), interpunkcija, sentiment varijansa, čitljivost, TextBlob, batch obrada, TF-IDF.

- **1. Subtitle loading**

Učitava se `final_movie_list.csv` , skenira se `data/raw/subtitles/` i mapira se `tmdb_id` → putanja fajla. Izračunava se koliko filmova ima titlove (npr. 7 423 od 12 722). Prikazuje se kratak primer sadržaja titla (sirovi tekst sa vremenskim oznakama).

- **2. Text cleaning demo**

Dve funkcije: **striktno čišćenje** (za statistike i TF-IDF) — uklanja vremenske oznake, HTML tagove, zagrade, ne-ASCII; **čišćenje za sentiment** — blaže, da ostane interpunkcija važna za emocije. Primer pre/posle na kratkom tekstu.


- **3. Full feature extraction**

Poziva se `process_subtitle_batch()` za sve fajlove: za svaki film se izvlače: broj reči, rečenica, prosečna dužina rečenice, broj karaktera, type-token ratio, hapax legomena ratio, jedinstvene reči; VADER sentiment (compound, pos, neg, neu); exclamation_ratio, question_ratio, sentiment_compound_std, emotional_intensity; avg_word_length, sentence_length_std; TextBlob polarity i subjectivity. Rezultat je tabela sa ~22 kolone (uključujući `id`). Trajanje: nekoliko minuta za ~7 400 fajlova.

- **4. Basic text stats — vizuelizacija**

Histogrami ili boxplot-ovi za `word_count` , `sentence_count` , `avg_sentence_length` , `char_count` .

Slika: `02_nlp_features_01_nlp_basic_text_stats.png` .




Šta pokazuje slika: Distribucije broja reči, rečenica, prosečne dužine rečenice i broja karaktera po filmu. Titlovi su tipično hiljade reči; ove mere ulaze u set `1_text_basic`.

• 5. Lexical diversity

Vizuelizacija type-token ratio, hapax legomena ratio, unique_words.

Slika: `02_nlp_features_02_nlp_lexical_diversity.png` .




Šta pokazuje slika: Type-token ratio, hapax legomena ratio i broj jedinstvenih reči — mere bogatstva vokabulara. Niže vrednosti znače repetitivniji dijalog; koriste se u `text_basic` setu.

• 6. Sentiment histograms

Distribucije VADER compound, pos, neg, neu. Većina filmova ima pozitivan compound (dijalog je često pozitivan u celini).

Slika: `02_nlp_features_03_nlp_sentiment_histograms.png` .




Šta pokazuje slika: VADER sentiment (compound, pozitivno, negativno, neutralno) po filmu. Većina titlova ima pozitivan compound — dijalog je u celini pozitivan; neutralna komponenta dominira. Ove kolone idu u set `2_text_+vader`.

• 7. Sentiment by success

Sentiment (npr. compound) podeljen po `is_commercial` ili `is_award_winner`. Da li uspešni filmovi imaju drugačiji sentiment.

Slika: `02_nlp_features_04_nlp_sentiment_by_success.png`.




Šta pokazuje slika: Poređenje sentimenta (npr. compound) između uspešnih i neuspešnih filmova. Ako se distribucije razlikuju, sentiment nosi signal za model; inače je doprinos ograničen.

- **8. NLP correlation heatmap**

Korelaciona matrica između NLP obeležja.

Slika: 02_nlp_features_05_nlp_correlation_heatmap.png .




Šta pokazuje slika: Korelacije između NLP obeležja. Neke mere su međusobno povezane (npr. word_count i char_count); korisno da se vidi da ne dupliramo isti signal u modelu.

- **9. TF-IDF**

Kreira se vektorajzer (npr. max 5000 terma, unigrami+bigrami, min_df/max_df, stop words). Fit na očišćenom korpusu; čuva se matrica (npz), vokabular (pkl) i ID-evi korpusa (pkl). Prikazuju se top TF-IDF reči (npr. „okay“, „uh“, „fuck“, „sir“ — tipičan dijalog).

Slika: 02_nlp_features_06_nlp_tfidf_top_terms.png .



Šta pokazuje slika: Reči sa najvećom TF-IDF težinom u korpusu titlova — tipično reči iz svakodnevnog dijaloga (okay, uh, sir, fuck). SVD od 5000 terma daje 100 komponenti koje ulaze u set 3_text_full.

- **Saving**

nlp_features.csv se upisuje u data/processed/ ; TF-IDF matrica i pomoćni fajlovi takođe.

Zaključak: Imamo numerička NLP obeležja za 7 423 filma i retku TF-IDF matricu za SVD u notebooku 03.

6. Notebook 03 — Baseline modeli

Notebook **03_baseline_models.ipynb** učitava glavni dataset i NLP obeležja, spaja ih, kreira žanr dummy-e, filtrira na filmove sa titlovima i validnim budget/revenue/runtime, dodaje SVD komponente iz TF-IDF matrice i definiše **8 progresivnih setova obeležja**. Zatim za svaki set i oba cilja radi stratifikovani split 70/15/15, opciono SMOTE na treningu, trenira LR, RF i XGBoost, prikuplja F1, F1 na optimalnom pragu, AUC i balansiranu tačnost. Na kraju prikazuje tabele, heatmape, konfuzione matrice, ROC krive i važnost obeležja.

6.1 Šta radi svaka sekcija

- **Setup**

Uvoze se `data_loader`, `models`, NumPy, Pandas, matplotlib, seaborn, TruncatedSVD, `scipy.sparse`, `pickle`. Postavlja se seed (42), putanje, `FIGURES_DIR`.

- **1. Data loading & feature engineering**

- `load_main_dataset`, `load_nlp_features`, `merge_datasets`; `get_unique_genres`, `create_genre_dummies`.
- Filtriranje: `word_count` ne null, `budget > 0`, `revenue > 0`, `runtime > 0` → **modeling_df** (npr. 5754 filma).
- Izvedene kolone: `title_length`, `budget_log`, `revenue_log`, `vote_count_log`, `release_month`, `release_year`.
- Učitavanje TF-IDF matrice i corpus IDs; TruncatedSVD sa 100 komponenti; merge SVD obeležja u `modeling_df` (`tfidf_svd_1 ... tfidf_svd_100`). Objašnjenje: 100 SVD komponenti daje „tekstualni“ signal za set `3_text_full`.

- **2. Feature set definitions**

- **1_text_basic**: samo osnovna NLP (`word_count`, `sentence_count`, `avg_sentence_length`, `char_count`, `type_token_ratio`, `hapax_legomena_ratio`, `unique_words`).
- **2_text_vader**: + `sentiment_compound`, `sentiment_pos`, `sentiment_neg`, `sentiment_neu`.
- **3_text_full**: + opcionalna NLP (`avg_word_length`, `sentence_length_std`, `textblob_sentiment_compound_std`, `exclamation_ratio`, `question_ratio`, `emotional_intensity`) + svih 100 `tfidf_svd` kolona.
- **4_genre**: + dummy žanrovi.
- **5_title**: + `title_length`.
- **6_budget**: + `budget_log`.
- **7_runtime**: + `runtime`.

- **8_+vote_revenue:** za **komercijalni** isti kao 7 (revenue se ne dodaje — leakage); za **nagrada** dodaju se vote_count_log i revenue_log.

Ispis broja obeležja po setu za commercial i award.

- **3. Progressive training (sets 1–3)**

Za setove 1_text_basic, 2_text_+vader, 3_text_full: za svaki cilj prepare_modeling_data → X, y; create_splits → stratifikovano 70/15/15; train_baseline(..., use_smote=True) za commercial i award. Rezultati se čuvaju u all_results[set_name] .

- **4. Progressive training (sets 4–6)**

Isto za 4_+genre, 5_+title, 6_+budget.

- **5. Progressive training (sets 7–8)**

Isto za 7_+runtime i 8_+vote_revenue.

- **6. Summary table**

results_table(all_results) — tabela Test F1, F1@opt, AUC, Bal.Acc. po feature setu i modelu za oba cilja.


(Nema posebne slike; tabela je u izlazu ćelije.)

- **7. Heatmaps**

Heatmape: F1 po setu i modelu; AUC po setu i modelu; Balanced Accuracy po setu i modelu.


Slike:

- 03_baseline_models_01_progressive_f1_heatmap.png




Šta pokazuje slika: F1 po feature setu (1–8) i modelu (LR, RF, XGB) za oba cilja. Rezultati rastu od teksta (1–3) ka punom setu (7–8); za commercial F1 oko 0,57–0,60, za award niži F1 zbog neuravnoteženosti.

- 03_baseline_models_02_progressive_auc_heatmap.png



Šta pokazuje slika: AUC po setu i modelu. AUC za award raste do ~0,77–0,83 na setu 8; za commercial oko 0,62–0,66. Modeli bolje rangiraju nego što klasifikuju na pragu 0,5.

- 03_baseline_models_03_progressive_bal_acc_heatmap.png




Šta pokazuje slika: Balansirana tačnost po setu i modelu. Trend sličan F1 i AUC; korisna za neuravnotežene ciljeve.

8. Commercial success — confusion matrix, ROC, feature importance

Za izabrani set (npr. 7_+runtime) i cilj `is_commercial`: konfuziona matrica na testu, ROC kriva (svi modeli), važnost obeležja (Random Forest / XGBoost).


Slike:

- 03_baseline_models_04_commercial_cm.png — konfuziona matrica (TP, FN, FP, TN).




Šta pokazuje slika: Za komercijalni uspeh na testu: broj TP, TN, FP, FN. Dijagonale (TP, TN) želimo veće; model nije savršen ali ima smisla.

- 03_baseline_models_05_commercial_roc.png — ROC krive za LR, RF, XGB.



Šta pokazuje slika: ROC krive za sva tri modela; što kriva više ulevo-gore, to bolji AUC. LR obično oko 0,66 AUC — solidno razlikuje uspešne od neuspešnih.

- 03_baseline_models_06_commercial_feat_imp.png — bar plot važnosti obeležja (npr. vote_count_log, budget_log, runtime, žanrovi).




Šta pokazuje slika: Koja obeležja najviše doprinose (RF/XGB): vote_count_log, budget_log, runtime i žanrovi. Metapodaci su jači signal od teksta za ovaj cilj.

• 9. Award prediction — confusion matrix, ROC, feature importance

Isto za is_award_winner (npr. set 7 ili 8).


Slike:

- 03_baseline_models_07_award_cm.png




Šta pokazuje slika: Konfuziona matrica za predikciju nagrade. Manjinska klasa je teška — mnogo lažno negativnih (FN) ili lažno pozitivnih (FP). Zato koristimo F1 na optimalnom pragu i AUC.

- 03_baseline_models_08_award_roc.png



Šta pokazuje slika: ROC krive za award: AUC ~0,77–0,83 na setu 8. Modeli dobro rangiraju filmove po verovatnoći nominacije; izbor praga (npr. na val skupu) poboljšava F1.

- 03_baseline_models_09_award_feat_imp.png — npr. vote_count_log, runtime, revenue_log, budget_log.




Šta pokazuje slika: Za predikciju nagrade najvažniji su vote_count_log, runtime, revenue_log i budget_log. Filmovi sa više glasova, dužim trajanjem i većim prihodom češće dobijaju nominaciju.

10. Baseline comparison

Bar plot upoređivanja modela (LR, RF, XGB) po F1 ili AUC za izabrani set.

Slika: 03_baseline_models_10_baseline_comparison.png



Šta pokazuje slika: Direktno poređenje LR, RF i XGB po F1 ili AUC za izabrani set. LR često malo vodi za commercial; za award svi su slični, sa prostora za poboljšanje tuningom i SVM-om u KT2.

6.2 Šta pokazuju slike baseline modela

Slika	Šta prikazuje
01–03 (heatmaps)	Kako F1, AUC i Bal.Acc. rastu sa dodavanjem obeležja (od teksta do metapodataka). Set 7 ili 8 obično daje najbolje rezultate.
04 (commercial CM)	Za komercijalni uspeh: broj tačnih/netečnih predikcija (TP, TN, FP, FN). Pokazuje da model nije savršen ali ima smisla.
05 (commercial ROC)	ROC krive: što je kriva više ulevo-gore, to bolji rang (AUC). LR na setu 7 obično oko 0.66 AUC.

Slika	Šta prikazuje
06 (commercial feat. imp.)	Koja obeležja najviše doprinose predikciji komercijalnog uspeha (npr. vote_count_log, budget_log, runtime).
07–09 (award)	Isto za predikciju nagrade: konfuzionna matrica, ROC (AUC ~0.77–0.83 za set 8), važnost obeležja (vote_count, runtime, revenue).
10 (comparison)	Jednostavno upoređivanje tri modela na jednom setu (npr. F1 ili AUC).

7. Šta koristimo, zašto, šta očekujemo i šta smo dobili

7.1 Tehnike i alati

Šta	Zašto
Stratifikovani split 70/15/15	Da train/val/test održe isti udeo pozitivnih kao celi dataset; val za izbor optimalnog praga.
SMOTE	Da smanjimo neuravnoteženost za nagrade (manjinska klasa ~15%); sintetički primeri manjinske klase.
class_weight='balanced'	Alternativa SMOTE-u; težine klase obrnuto srazmerne učestalosti. U praksi za award često bolje od SMOTE-a (manje overfittinga).
StandardScaler	Sva obeležja na istu skalu pre LR i često pre drugih modela.
TruncatedSVD (100)	Smanjuje dimenzionalnost TF-IDF (5000 kolona) na 100 komponenti; olakšava učenje i smanjuje šum.
F1 i AUC	F1 — balans preciznosti i odziva; AUC — kvalitet rangiranja. Za neuravnotežene ciljeve koristimo i F1 na optimalnom pragu (prag izabran na val skupu).
LR, RF, XGB	LR — linearni baseline; RF i XGB — nelinearni, robusni; bez tuninga na KT1.

7.2 Očekivanja (KT1) i ostvareni rezultati

- **Komercijalni uspeh (bez revenue u obeležjima):**

Očekivano F1 ~0.60–0.68, AUC ~0.70–0.78 za set sa runtime.

Dobijeno: F1 ~0.60 (LR na 7_+runtime), F1@opt ~0.65, AUC ~0.66. U skladu sa očekivanjima; LR malo ispred RF/XGB.

- **Nagrada:**

Očekivano F1(opt) ~0.50–0.55, AUC ~0.78–0.87.

Dobijeno: Sa setom 8_+vote_revenue i SMOTE: F1(opt) ~0.50–0.51 (LR), AUC ~0.83 (LR). Sa class_weight umesto SMOTE: F1(opt) može biti ~0.51; AUC ~0.80. Zadovoljavajuće za baseline.

7.3 Da li smo zadovoljni?

Jesmo u okviru KT1:

- Pipeline je jasan i reproduktivnan; EDA i sve slike objašnjavaju podatke i rezultate.
- NLP obeležja su uključena (od teksta do TF-IDF SVD i metapodataka).
- Nema data leakage za komercijalni uspeh.
- Baseline rezultati su u liniji sa specifikacijom (F1 i AUC u navedenim granicama).

Šta bismo poboljšali u KT2:

- Optimizacija hiperparametara (RF, XGB, eventualno SVM).
- Za nagradu: class_weight kao podrazumevano; eventualno ADASYN/Borderline-SMOTE.
- Analiza grešaka (koji filmovi su konzistentno pogrešno klasifikovani).
- Ensembli (voting, stacking).

8. Zaključak

U ovoj specifikaciji za **prvu kontrolnu tačku (KT1)** detaljno je opisana **cela Faza 1** projekta Movie NLP Success Analyzer: **kako smo prikupili podatke** (pipeline od 10 skripti u `data_pipeline/`), **šta imamo** (finalna tabela, titlovi, NLP obeležja, tri notebooka i zajednički kod), **šta radi svaka ćelija** u notebookima 01, 02 i 03, i **šta znače sve slike** u `figures/`. Takođe je objašnjeno **šta koristimo i zašto** (split, SMOTE, skaliranje, SVD, metrike), **šta smo očekivali i šta smo dobili**, te **da li smo zadovoljni** (jesmo za KT1; poboljšanja ostaju za KT2). Specifikacija je pisana tako da bude razumljiva i čitaocima bez dubokog predznanja algoritama i NLP tehnika, uz Mermaid dijagrame za pregled pipeline-a i strukture Phase 01.